

Newton 型优化方法项目报告

1. 算法简介

本项目实现了 5 类方法：

Gradient Descent, Classical Newton, Modified Damped Newton, CG, Newton-CG. (1)

固定步长梯度下降

$$x_{k+1} = x_k - \alpha \nabla f(x_k). \quad (2)$$

实验 1 中

$$\alpha = 0.2. \quad (3)$$

优点：单步便宜。缺点：只用一阶信息，通常线性收敛。

经典 Newton 方法

Newton 方向满足

$$\nabla^2 f(x_k) d_k = -\nabla f(x_k), \quad (4)$$

迭代为

$$x_{k+1} = x_k + d_k. \quad (5)$$

若 x_k 充分接近非退化极小点，且 Hessian 正定，则通常有

$$\|x_{k+1} - x^*\| = O(\|x_k - x^*\|^2). \quad (6)$$

修正阻尼 Newton 方法

先修正 Hessian：

$$\tau_k = \max\{0, \delta - \lambda_{\min}(\nabla^2 f(x_k))\}, \quad (7)$$

$$B_k = \nabla^2 f(x_k) + \tau_k I, \quad \delta = 10^{-3}. \quad (8)$$

方向：

$$B_k d_k = -\nabla f(x_k). \quad (9)$$

若 $B_k \succ 0$ 且 $g_k = \nabla f(x_k) \neq 0$, 则

$$d_k = -B_k^{-1} g_k, \quad (10)$$

$$g_k^T d_k = -g_k^T B_k^{-1} g_k < 0. \quad (11)$$

所以 d_k 是下降方向。

Armijo 回溯线搜索选择 t_k :

$$f(x_k + t_k d_k) \leq f(x_k) + c_1 t_k \nabla f(x_k)^T d_k, \quad (12)$$

其中代码使用

$$c_1 = 10^{-4}, \quad \rho = 0.5. \quad (13)$$

Newton-CG

Newton-CG 用 CG 近似求解

$$\nabla^2 f(x_k) d_k = -\nabla f(x_k). \quad (14)$$

内层停止准则:

$$\|\nabla^2 f(x_k) d_k + \nabla f(x_k)\| \leq \eta_k \|\nabla f(x_k)\|. \quad (15)$$

实验 3 比较:

$$\eta_k = 0.8, \quad \eta_k = 0.1, \quad \eta_k = \min\{0.5, \|\nabla f(x_k)\|\}. \quad (16)$$

2. 梯度与 Hessian 公式

实验 1

目标函数:

$$f_1(x, y) = x^4 + y^4 + x^2 + y^2 + 0.5xy. \quad (17)$$

梯度:

$$\nabla f_1(x, y) = \begin{bmatrix} 4x^3 + 2x + 0.5y \\ 4y^3 + 2y + 0.5x \end{bmatrix}. \quad (18)$$

Hessian:

$$\nabla^2 f_1(x, y) = \begin{bmatrix} 12x^2 + 2 & 0.5 \\ 0.5 & 12y^2 + 2 \end{bmatrix}. \quad (19)$$

初始点与极小点:

$$x_0 = (1, 1)^T, \quad x^* = (0, 0)^T. \quad (20)$$

实验 2

目标函数：

$$f_2(x, y) = 0.5x^2 + 0.25y^4 - 0.5y^2. \quad (21)$$

梯度：

$$\nabla f_2(x, y) = \begin{bmatrix} x \\ y^3 - y \end{bmatrix}. \quad (22)$$

Hessian：

$$\nabla^2 f_2(x, y) = \begin{bmatrix} 1 & 0 \\ 0 & 3y^2 - 1 \end{bmatrix}. \quad (23)$$

驻点：

$$(0, 0), \quad (0, 1), \quad (0, -1). \quad (24)$$

分类：

$$\nabla^2 f_2(0, 0) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \quad (25)$$

所以 $(0, 0)$ 是鞍点。

$$\nabla^2 f_2(0, \pm 1) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \succ 0, \quad (26)$$

所以 $(0, \pm 1)$ 是局部极小点。

实验 3

目标函数：

$$f_3(x) = \frac{1}{2}x^T A x + \frac{c}{4} \sum_{i=1}^n x_i^4. \quad (27)$$

参数：

$$n = 200, \quad c = 0.5, \quad A = \text{diag}(a_1, \dots, a_n). \quad (28)$$

其中

$$a_i \in [10^{-3}, 10^1] \quad (29)$$

按对数间隔生成。

梯度：

$$\nabla f_3(x) = A x + c x^{\circ 3}. \quad (30)$$

分量形式：

$$[\nabla f_3(x)]_i = a_i x_i + c x_i^3. \quad (31)$$

Hessian:

$$\nabla^2 f_3(x) = \text{diag}(a_i + 3c x_i^2)_{i=1}^n. \quad (32)$$

Hessian-vector product:

$$\nabla^2 f_3(x)v = ((a_i + 3c x_i^2)v_i)_{i=1}^n. \quad (33)$$

初始点:

$$x_0 = (1, 2, 1, 2, \dots)^T. \quad (34)$$

极小点:


$$x^* = 0. \quad (35)$$

3. 实验 1: Newton 的快速局部收敛


比较:

$$\text{Gradient Descent} \quad \text{vs.} \quad \text{Classical Newton}. \quad (36)$$

Experiment 1 Iteration Paths



Experiment 1 Error Curves



结果：

方法	迭代数	$f(x_k)$	$\ \nabla f(x_k)\ $	最终点
Gradient Descent	35	5.2076×10^{-22}	5.1027×10^{-11}	$(-1.4433 \times 10^{-11}, -1.4433 \times 10^{-11})$
Newton	5	1.6881×10^{-24}	2.9053×10^{-12}	$(8.2173 \times 10^{-13}, 8.2173 \times 10^{-13})$

Newton 误差与观测阶：

k	$\ x_k - x^*\ _2$	q_k
0	1.4142	-
1	7.8026×10^{-1}	-
2	3.0882×10^{-1}	1.5585
3	3.8345×10^{-2}	2.2507
4	8.9889×10^{-5}	2.9029
5	1.1621×10^{-12}	2.9994

问题回答：

1. Newton 为什么更快？

$$d_k = -(\nabla^2 f(x_k))^{-1} \nabla f(x_k). \quad (37)$$

它使用曲率信息。靠近极小点时，二次模型很准，所以局部收敛很快。

2. 梯度下降为什么 zigzag?

狭长等高线表示 Hessian 条件数大：

$$\kappa(\nabla^2 f) \gg 1. \quad (38)$$

负梯度方向常横穿谷底，固定步长容易左右震荡。

3. 是否支持 Newton 的快速局部收敛?

支持。实验中

$$35 \text{ iterations} \quad \text{vs.} \quad 5 \text{ iterations}. \quad (39)$$

观测阶最后接近 3，原因是本实验有对称结构：

$$x_0 = y_0, \quad f_1(x, y) = f_1(y, x). \quad (40)$$

迭代保持在

$$x = y \quad (41)$$

上，因此出现特殊的近三阶现象。一般 Newton 理论结论仍是局部二次收敛。

4. 实验 2: 鞍点与 Hessian 修正


比较：


$$\text{Classical Newton} \quad \text{vs.} \quad \text{Modified Damped Newton}. \quad (42)$$

初始点：

$$x_0 = (0.1, 0.1)^T. \quad (43)$$

Experiment 2 Iteration Paths





结果：

方法	迭代数	$f(x_k)$	$\ \nabla f(x_k)\ $	最终点
Classical Newton	3	≈ 0	9.9262×10^{-24}	$(0, -9.9262 \times 10^{-24})$
Modified Damped Newton	5	-0.25	4.6107×10^{-11}	$(0, 1.0000000000230533)$

问题回答：

1. Classical Newton 为什么会被鞍点吸引？

Newton 解的是

$$\nabla f(x) = 0. \quad (44)$$

但

$$\nabla f(x) = 0 \quad (45)$$

只说明 x 是驻点，不保证是极小点。

本实验中

$$(0, 0) \quad (46)$$

是鞍点，但 classical Newton 收敛到它。

2. Hessian 不定时，Newton 方向为什么不一定下降？

Newton 方向:

$$d = -H^{-1}g. \quad (47)$$

下降条件:

$$g^T d < 0. \quad (48)$$

若 $H \succ 0$:

$$g^T d = -g^T H^{-1}g < 0. \quad (49)$$

若 H 不定, 则

$$g^T H^{-1}g \quad (50)$$

可正可负, 所以 $g^T d$ 不一定小于 0。

3. 为什么修正方向是下降方向?

若

$$B_k \succ 0, \quad B_k d_k = -g_k, \quad (51)$$

则

$$d_k = -B_k^{-1}g_k. \quad (52)$$

所以

$$g_k^T d_k = -g_k^T B_k^{-1}g_k < 0. \quad (53)$$

4. Armijo line search 的作用是什么?

Hessian 修正确保

$$d_k \text{ is descent.} \quad (54)$$

Armijo 确保

$$f(x_{k+1}) < f(x_k) \quad (55)$$


具有充分下降。二者结合避免收敛到鞍点, 并收敛到

$$(0, 1). \quad (56)$$


5. 实验 3: Inexact Newton / Newton-CG

目标: 比较不同 forcing term。

Experiment 3 Gradient Norms



Experiment 3 Cumulative CG Iterations



结果:

η_k	外层迭代数	总 CG 次数	$f(x_k)$	$\ \nabla f(x_k)\ $
0.8	79	961	1.8633×10^{-19}	9.8512×10^{-11}
0.1	16	861	2.5440×10^{-20}	4.0393×10^{-11}
$\min(0.5, \ \nabla f(x_k)\)$	15	1149	3.7214×10^{-24}	8.2076×10^{-13}

问题回答：

1. 为什么 $\eta_k = 0.8$ 单步便宜但外层迭代多？

停止条件宽松：

$$\|Hd + g\| \leq 0.8\|g\|. \quad (57)$$

CG 早停，单步便宜；但方向粗糙，外层下降慢。

2. 为什么 $\eta_k = 0.1$ 更准确但可能更贵？

停止条件更严格：

$$\|Hd + g\| \leq 0.1\|g\|. \quad (58)$$

方向更接近精确 Newton 方向，外层迭代少；但每步 CG 可能更多。

3. 为什么自适应规则能平衡成本？

$$\eta_k = \min(0.5, \|\nabla f(x_k)\|). \quad (59)$$

远离解时：

$$\|\nabla f(x_k)\| \text{ large} \Rightarrow \eta_k \approx 0.5. \quad (60)$$

接近解时：

$$\|\nabla f(x_k)\| \rightarrow 0 \Rightarrow \eta_k \rightarrow 0. \quad (1)$$

因此早期少算，后期精算。

4. 本实验说明了 inexact Newton 的什么思想？

不必精确解 Newton 方程：

$$Hd = -g. \quad (2)$$

只需控制残差：

$$\|Hd + g\| \leq \eta_k \|g\|. \quad (3)$$

核心权衡：

$$\text{inner CG cost} \quad \leftrightarrow \quad \text{outer Newton convergence}. \quad (4)$$

6. Newton 型方法的优点与局限

优点：

uses curvature information (5)

$\Rightarrow$ fast local convergence. (6)

在极小点附近:

$$\|x_{k+1} - x^*\| = O(\|x_k - x^*\|^2). \quad (7)$$

Hessian 可自动缩放方向:

$$d_k = -H_k^{-1}g_k. \quad (8)$$

因此比梯度下降更少 zigzag。

局限:

1. 可能收敛到非极小驻点:

$$\nabla f(x) = 0 \not\Rightarrow x \text{ is minimizer.} \quad (9)$$

2. Hessian 不定时方向可能非下降:

$$H_k \not\succeq 0 \Rightarrow g_k^T d_k \not\leq 0. \quad (10)$$

3. 精确 Newton 单步代价高:

$$H_k d_k = -g_k \quad (11)$$

需要解线性系统。

4. 大规模问题需要近似:

$$\text{Newton-CG, Hessian-vector product, forcing term.} \quad (12)$$

总结:

$$\text{Newton is fast but needs safeguards.} \quad (13)$$

实际可靠实现通常需要

$$\text{Hessian modification + line search + inexact solve.} \quad (15)$$